Universidad del Valle
Visión por computadora

Alina Carías, Daniel Machic,
Ariela Mishaan

Laboratorio 7

Repositorio de github:

https://github.com/ArielaMishaanCohen/LAB7.git

Task 1

Pregunta 1.1

El médico coordinador del proyecto le presenta la siguiente situación: Tenemos 800 radiografías etiquetadas por nuestros radiólogos. Un colega me dijo que con tan pocos datos el modelo va a memorizar todo y no va a servir para nada en producción."

Como ingeniero de IA a cargo, usted decide aplicar Data Augmentation como parte de la solución. Sin embargo, el médico le pregunta: "¿No estamos inventando datos falsos que podrían confundir al modelo?

1. **Explíquele al médico, en términos que él pueda entender, qué es el Data Argumentation y por qué las imágenes generadas no son datos falsos. Use la analogía que considere más apropiada.**
   Imaginé que tiene una radiografía de un paciente. Si fotografía desde un ángulo ligeramente distinto, con diferente iluminación, o si el paciente estaba un poco rotado al momento del estudio, el resultado es una imagen diferente, pero sigue siendo la radiografía del mismo pulmón, con la misma condición. Data Argumentation hace eso de forma controlada: toma las 800 radiografías reales y genera versiones con pequeñas variaciones (rotación leve, cambio de brillo, espejo horizontal) que representan condiciones reales de captura. No se inventa patología nueva ni se alteran estructuras de diagnóstico; solo se simula la variabilidad natural que el modelo va a ver en producción. Es como practicar leer la misma letra en distintas caligrafías, no se están inventando letras, si no que se está aprendiendo a reconocerla bajo condiciones diferentes.

2. **En el contexto específico de radiografías de tórax, proponga tres transformaciones de Data Augmentation que serían válidas y justifique cada una. Luego, identifique una transformación que no debería aplicarse en este dominio médico y explique por qué podría comprometer la integridad diagnóstica del modelo.**
   - Rotación leve: un paciente puede que no esté perfectamente centrado en el equipo de rayos x. Una rotación pequeña replica esa variabilidad sin desplazar anatomía crítica fuera del frame.
   - Ajuste de brillo/contraste: diferentes equipos de rayos X y distintas dosis de exposición producen imágenes con diferentes iluminaciones. Esa transformación entrena al modelo a ser robusto ante esas diferencias de hardware, algo especialmente relevante en clínicas rurales con equipos variados.
   - Flip horizontal: los pulmones tienen cierta simetría bilateral. Un flip horizontal produce una radiografía anatómicamente aceptable.
   - Transformación inválida – Zoom/Crop agresivo: Recortar fuertemente la imagen puede eliminar regiones del pulmón que son diagnósticamente relevantes. Un

modelo entrenado con imágenes recortadas podría ignorar zonas donde la neumonía se manifiesta frecuentemente, comprometiendo su sensibilidad clínica.

3. **¿Es el Data Augmentation suficiente por sí solo para garantizar que el modelo generalice bien? Argumente su posición considerando otras variables del proceso de entrenamiento.**
   No. El data augmentation agranda la variabilidad aparente del set de entrenamiento, pero no reemplaza datos reales diversos. Hay otras variables críticas: la arquitectura del modelo (debe tener la capacidad adecueda, ni demasiado compleja ni demasiado simple), la regularización (dropout, weight decay) para penalizar la memorización, la función de pérdida (en clases desbalanceadas, cross-entropy simple puede ser insuficiente), y la calidad del etiquetado (800 imágenes con etiquetas inconsistentes son peores que 500 bien etiquetadas). El augmentation reduce el overfitting pero no lo elimina si el modelo es excesivamente profundo para el volumen de datos disponible.

<u>Pregunta 1.2</u>

Durante el entrenamiento del modelo de MediScan Guatemala, el equipo registra las siguientes curvas de pérdida (loss) al finalizar 25 épocas.

4. **Identifique a partir de qué época aproximada comienza el sobreajuste (overfitting) y describa cómo se evidencia en los números de la tabla.**
   El overfitting comienza a evidenciarse claramente a partir de la época 15. Hasta la época 10, ambas pérdidas bajan en paralelo (training: 0.52 -> 0.31, validation: 0.55 -> 0.38), lo cual indica aprendizaje real. En la época 15, el training los sigue bajo (0.18) pero el validation los sigue bajando (0.18) pero el validation loss sube de 0.38 a 0.42, la cual es la primera señal de divergencia. Para las épocas 20 y 25, la brecha se vuelve más grande: training en 0.04 mientras validation llega a 0.89. El modelo memoriza los datos de entrenamiento en lugar de aprender patrones generalizables.

5. **Proponga dos estrategias de regularización concretas (por ejemplo, Dropout o L2) que podría haber implementado para prevenir este comportamiento. Para cada una, explique intuitivamente qué fenómeno matemático está mitigando y qué impacto esperaría ver en las curvas de la tabla.**
   - Dropout: Durante el entrenamiento, apaga aleatoriamente un porcentaje de neuronas en cada forward pass. Matemáticamente, impide que la red desarrolle co-adaptaciones entre neuronas especificas (es decir, que un grupo de neuronas aprenda a “compensarse” para memorizar casos específicos). El efecto esperado en la tabla sería que la validation los deje de subir después de la época 15 y se estabilice en un valor cercano al training los, aunque este último ya no bajaría tan agresivamente.
   - L2 Regularization (Weight Decay): Agrega un término de penalización a la función de pérdida proporcional a la magnitud de los pesos. Esto desalienta que los pesos crezcan demasiado para ajustarse a casos específicos del training set. En la tabla, el training los no descendería tan rápido (no llegaría a 0.04), pero la validation los que se mantendría más cercana y no subiría a 0.89.

6. **Desde una perspectiva médica, ¿por qué es especialmente peligroso desplegar en producción un modelo que exhibe este patrón de sobreajuste para el diagnóstico de radiografías? Argumente más allá de los números**
   Un modelo con este patrón de overfitting aprende las particularidades del set de entrenamiento, posiblemente incluyendo artefactos del equipo, marcadores en las imágenes, o características demográficas específicas de los 800 pacientes, en lugar de los patrones clínicos reales de la neumonía. En producción, ante una radiografía de una paciente de una clínica distinta o tomada con un equipo diferente, el modelo podría llegar a fallar de manera impredecible. En diagnóstico médico esto se traduce en falsos negativos: pacientes con neumonía que el modelo clasifica como normales y que no recibirán tratamiento adecuado. A diferencia de otros dominios donde un error es un inconveniente, aquí puede ser la diferencia entre tratamiento a tiempo y una complicación grave. El médico que recibe la recomendación del sistema puede reducir su investigación clínica y confiar en una herramienta con 94% de accuracy aparente, creando un riesgo mayor.

<u>Pregunta 1.3</u>

Un inversionista que asiste a la demo del proyecto le pregunta: "¿Por qué su modelo tiene un 94% de accuracy en las pruebas? ¿Eso significa que es confiable para diagnosticar neumonía?"

Usted sabe que el dataset de prueba contiene 700 radiografías normales y solo 150 radiografías con neumonía.

7. **Calcule cuál sería el accuracy de un modelo naive que simplemente predice siempre 'Normal' para todas las imágenes. ¿Qué revela ese cálculo sobre el 94% reportado?**
   Total de imágenes:
   $$700 + 150 = 850$$
   Un modelo que siempre predice “normal” acierta en las 700 normales y falla en las 150 con neumonía.
   $$Accuracy\ naive = \frac{700}{85} = 82.4\%$$
   Esto quiere decir que, el 94% reportado apenas supera en más o menos 11.6 puntos a un modelo completamente inútil que nunca detecta neumonía. No es evidencia de un modelo confiable, es evidencia de una dataset desbalanceado donde la clase mayoritaria domina la métrica.

8. **Explique por qué, en problemas médicos con clases desbalanceadas, métricas como el F1-Score o la Sensibilidad (Recall) para la clase minoritaria son más informativas que el accuracy. No se limite a definirlas; argumente su relevancia clínica.**
   El **Recall (sensibilidad)** para la clase neumonía mide: de todos los pacientes que realmente tienen neumonía. En un sistema de apoyo diagnóstico, un Recall bajo significa pacientes enfermos sin diagnóstico, el pero resultado clínico posible. El

accuracy no distingue entre este error y un falso positivo, que aunque sea indeseable, tiene consecuencias menos graves: un examen adicional, no una neumonía sin tratar.

El **F1-Score** equilibra precisión y recall, penalizando modelos que logran alto Recall a costa de etiquetar todo como neumonía. En contexto clínico, es útil porque también importa no saturar al médico con falsos positivos. Pero si hubiera que elegir una sola métrica para este sistema, el recall de la clase positiva es prioritario: en medicina de primer nivel, se prefiere sobre diagnosticar y que el doctor descarte, que diagnosticar mal y que el paciente no reciba la atención necesaria.

9. **Como director técnico, ¿cómo le respondería al inversionista de forma honesta y profesional? Redacte una respuesta breve (3 a 5 oraciones) que sea técnicamente sólida pero comprensible para un no-especialista.**
   El 94% de exactitud es un punto de partida bueno, pero no es suficiente afirmar que modelo es clínicamente confiable. En nuestra prueba, 8 de cada 10 imágenes son de pulmones normales, por lo que un sistema que siempre diga 'normal' ua alcanzaría el 82% sin haber aprendido nada. Lo que realmente importa para este sistema es cuántos casos de neumonía detecta bien, y eso aún se esta validando con más atención. Antes de ponerlo en clínicas, poner el modelo a una evaluación clínica independiente con radiólogos para garantizar que sus recomendaciones sean seguras.

Task 2

<u>Pregunta 2.1</u>

"Para el modelo de radiografías no tiene sentido usar Transfer Learning desde ImageNet; ese dataset tiene fotos de perros, gatos y autos. Las radiografías son imágenes en escala de grises totalmente distintas. Mejor entrenamos desde cero para no contaminar el modelo."

1. **¿Está de acuerdo con el desarrollador? Argumentar con base en lo que las capas convolucionales tempranas de una CNN realmente aprenden y por qué ese conocimiento sí es transferible, incluso entre dominios visualmente distintos.**
   No estoy de acuerdo con el desarrollador. Aunque ImageNet sí tiene imágenes muy distintas, las primeras capas de una CNN no aprenden objetos específicos, sino patrones básicos visuales como bordes, texturas, gradientes de intensidad y formas simples. Estos patrones también se pueden ver en las radiografías médicas (por ejemplo un borde puede representar la orilla de un pulmón, o una textura podría mostrar la condición del tejido). Dado que las capas tempranas aprenden estas características universales, el conocimiento de ImageNet sí es transferible, aunque sea en temas distintos. Entrenar desde cero implicaría que el modelo tenga que volver a entender estos patrones básicos, lo cual es ineficiente para solo 800 imágenes.

2. **Más allá del argumento técnico, ¿cuál es el costo real de entrenar desde cero para un startup como MediScan Guatemala? Considerar al menos dos dimensiones distintas a la puramente computacional (ej. tiempo al mercado, riesgo, talento humano).**

Entrenar desde cero no solo es más caro computacionalemente sino también implica otros contratiempos:

- Tiempo al mercado: se necesitarían muchas más épocas y experimentación de los modelos. Esto retrasa la implementación del sistema en las clínicas. En el contexto médico, esto significa pacientes sin apoyo diagnóstico por más tiempo.
- Riesgo técnico: con pocos datos, el modelo probablemente tenga sobreajuste. Esto da un alto riesgo de obtener un modelo poco confiable, que en este contexto es peligroso.
- Talento humano: entrenar desde cero requiere más experiencia para ajustar la arquitectura e hiperparámetros desde cero.

3. **¿Existe algún escenario legítimo en el que usted sí consideraría entrenar desde cero en lugar de hacer transfer learning?**
   Por ejemplo, si se tuviera un dataset muy grande y específico del dominio médico (por ejemplo decenas de miles de radiografías), podría valer la pena entrenar desde cero. Otro caso es en el que el dominio sea muy diferente estructuralmente (imágenes demasiado distintas como MRIs en 3D). Si el uso de transfer learning resultara en sesgos o resultados no óptimos, se tendría que evaluar la opción también.

<u>Pregunta 2.2</u>

Equipo debe decidir estrategia de Fine Tuning.

4. **Dada la naturaleza del dataset médico disponible, ¿cuál opción recomendaría y por qué?**
   Creo que la mejor estrategia sería una combinada. Pero si hubiera que escoger entre una de las dos, creo que la opción A es la mejor, es decir, congelar toda la red base. La razón es que dado nuestro dataset tan pequeño, existe un riesgo muy alto de sobreajuste y si se descongelan todas las capas, se podría perder la capacidad de generalización. Además, el modelo perdería la capacidad de reconocer patrones básicos como bordes y texturas. En la opción A, en cambio, se aprovechan las features ya aprendidas y se reduce el riesgo del sobreajuste.

5. **¿Qué riesgo específico correría si aplica la opción B con una taza de aprendizaje alta (ej. 1e-3) en toda la red?**
   El riesgo principal de usar el B con tasa de aprendizaje alta es el fenómeno que se llama "olvido catastrófico". Esto significa que el modelo pierde rápidamente los patrones útiles qeu aprendió en ImageNet, adaptándose demasiado rápido a un dataset pequeño. Al final aprende solo ruido o patrones no generalizables. Durante el entrenamiento, esto se vería como una pérdida que baja demasiado rápida (en train), mientras que la pérdida de la validación sube o varía demasiado. Los resultabels del entrenamiento serían inestables.

6. **Si con el tiempo MediScan Guatemala logra recolectar 50000 radiografías etiquetadas, ¿cambiaría su recomendación?**

Sí. Si se tuvieran muchos más datos, sería más útil la opción B de descongelar más capas, pero manteniendo un learning rate bajo en las capas iniciales y uno más alto en el cabezal final. Esto es porque ya tendríamos suficientes datos para reducir el riesgo del sobreajuste y permitir que el modelo aprenda más patrones específicos del ámbito médico que se está analizando.

Pregunta 2.3

Requerimiento: expandir sistema para que también detecte fracturas en radiografías de muñeca, usando el mismo modelo que se tiene para la neumonía. ¿Se puede reutilizar directamente o se tiene que empezar todo de nuevo?

7. **Evaluar la viabilidad de reutilizar el modelo de neumonía para el nuevo problema de fracturas en al muñeca. ¿Qué partes del modelo podrían aprovecharse y cuáles habría que modificar?**
   Considero que sí es viable reutilizar el modelo, pero con algunos cambios. Se podrían aprovechar las capas tempranas, que aprenden patrones generales como bordes, texturas y formas. Sin embargo, lo que sí valdría la pena modificar son las últimas capas, que se especializan en detectar neumonía en pulmones, y no sirven directamente para detectar fracturas. El nuevo cabezal de clasificación cambiaría completamente, porque ahora tendría que clasificar entre fractura y no fractura.

8. **Proponer un plan de acción concreto de 3 pasos para adaptar el modelo exitente al nuevo dominio. Ser específico: ¿Qué congela, qué descongela, qué modifica en el cabezal, qué tasa de aprendizaje usaría y por qué?**
   - **Reemplazar el cabezal:** cambiar la capa final por una nueva. Ahora la salida binaria sería fractura/no fractura. El learning rate para esta capa sería 1e-3.
   - **Congelar capas tempranas:** congelar las primeras capas (features generales). Entrenar solo las últimas capas y el cabezal. La base queda congelada.
   - **Fine-tuning gradual:** descongelar las últimas capas progresivamente. Ajustar con learning rate bajo (1e-5) para adaptar el modelo al nuevo dominio sin perder lo que se aprendió antes.

9. **¿Qué riesgo ético o clínico implica reutilizar un modelo entrenado en un dominio para otro dominio médico sin una validación rigurosa? ¿Qué proceso de validación mínimo recomendaría antes de desplegarlo?**
   El riesgo principal de reutilizar el modelo sin validación puede llevar a diagnósticos incorrectos (falsos negativos o positivos), pérdida de confianza médica y daño al paciente. La validación mínima recomendada sería que antes de desplegar el sistema, se pruebe con fotos que nunca se vieron durante el entrenamiento para volver a evaluar el rendimiento con métricas relevantes (como recall, F1-score, precision - no solo accuracy). Además, recomendaría evaluación humana de expertos antes de desplegar el sistema y también probarlo en distintos hospitales y con distintos equipos para asegurar la generalización.

Task 4

Comentario en post de linkedin

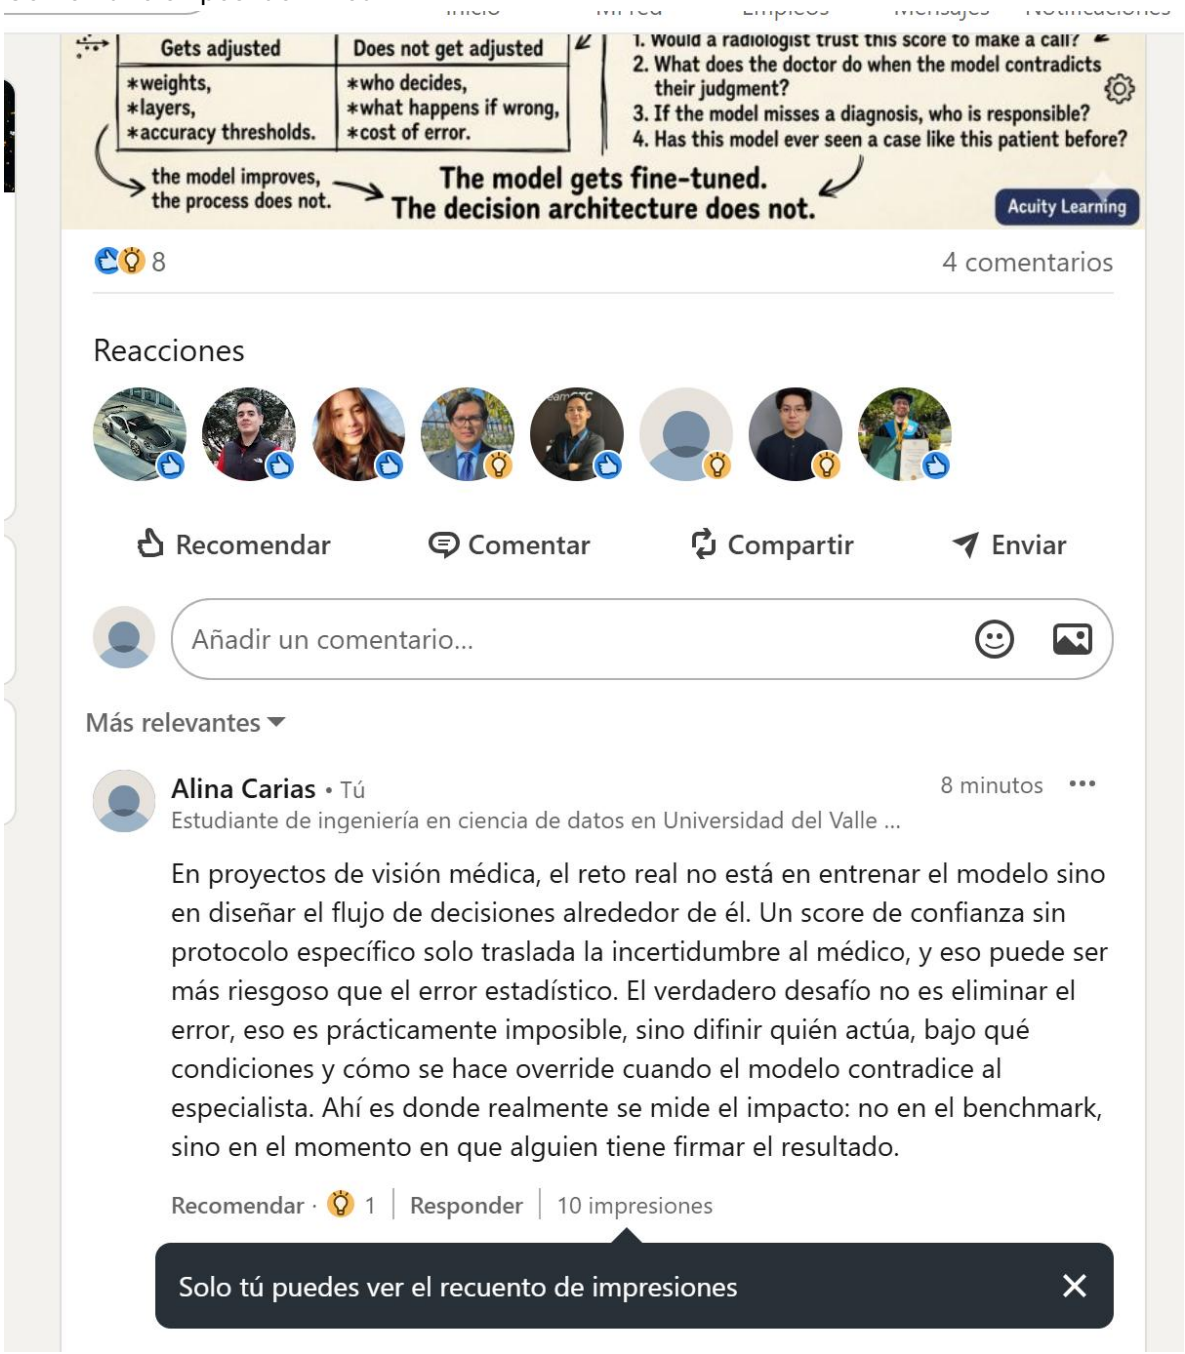

Link de comentario:
https://www.linkedin.com/feed/update/urn:li:activity:7439702171182551041?commentUrn=urn%3Ali%3Acomment%3A%28activity%3A7439702171182551041%2C7443079280428961792%29&dashCommentUrn=urn%3Ali%3Afsd_comment%3A%2874430792804289617 92%2Curn%3Ali%3Aactivity%3A7439702171182551041%29